Scalable IO in Java

Doug Lea
State University of New York at Oswego
dl@cs.oswego.edu
http://gee.cs.oswego.edu/dl/cpjslides/nio.pdf

译者：顿悟源码

代码实现：https://github.com/rxwheel/Reactor

大纲

- 可扩展的网络服务
- 事件驱动
- Reactor 模式
  - 基本版本
  - 多线程版本
  - 其他变种
- java.nio 非阻塞 IO APIs 的介绍

网络服务

- Web 服务，分布式对象等
- 大部分都有相同的基本结构：
  - 读取请求，**Read request**
  - 解析请求，**Decode request**
  - 业务处理，**Process service**
  - 编码响应，**Encode reply**
  - 发送响应，**Send reply**
- 但每一步的本质和开销不同
  - 解析 XML，传输文件，生成 Web 页面，计算服务，…

典型的服务端设计

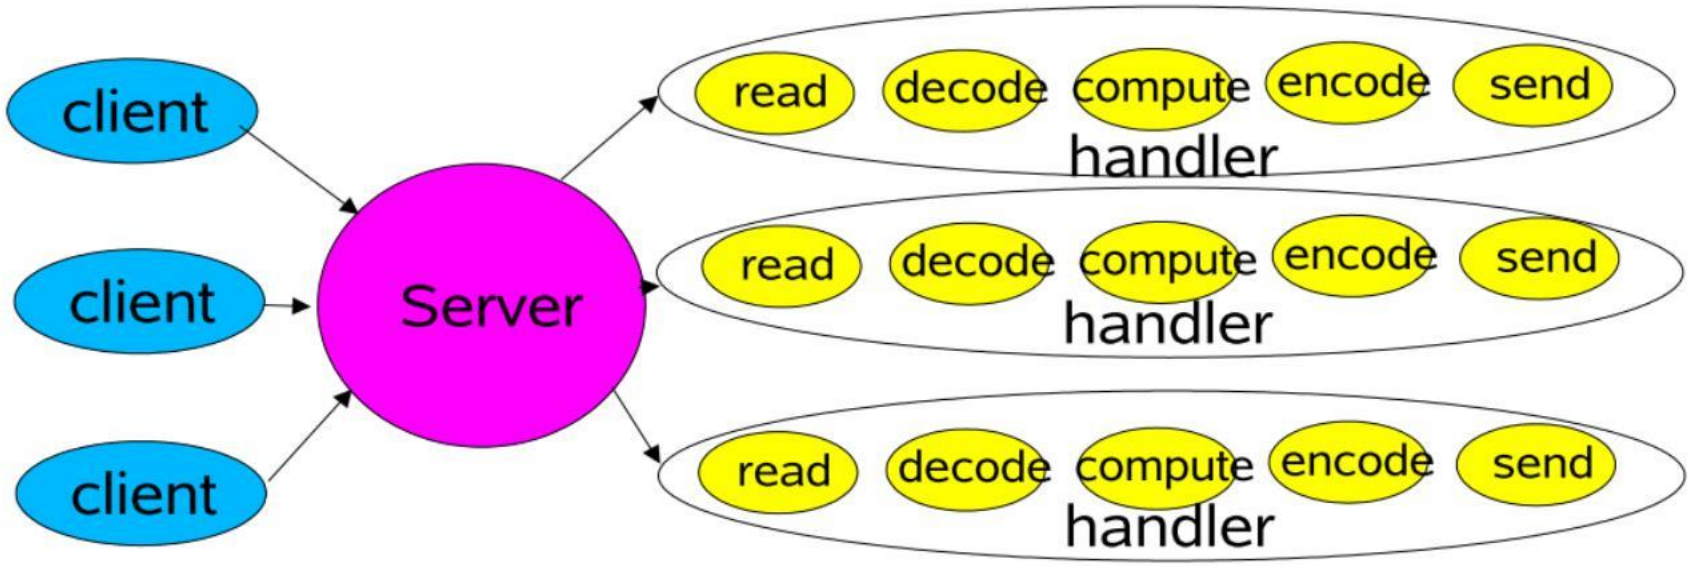

每个 handler 可能在各自的线程中

经典 ServerSocket 循环

```
class Server implements Runnable {
  public void run() {
    try {
      ServerSocket ss = new ServerSocket(PORT);
      while (!Thread.interrupted())
        new Thread(new Handler(ss.accept())).start();
      // or, single-threaded, or a thread pool
    } catch (IOException ex) { /* ... */ }
  }
  static class Handler implements Runnable {
    final Socket socket;
    Handler(Socket s) { socket = s; }
    public void run() {
      try {
        byte[] input = new byte[MAX_INPUT];
        socket.getInputStream().read(input);
        byte[] output = process(input);
        socket.getOutputStream().write(output);
      } catch (IOException ex) { /* ... */ }
    }
    private byte[] process(byte[] cmd) { /* ... */ }
  }
}
```

Note: most exception handling elided from code examples

可扩展点

- 在负载不断增加的情况下，如何优雅的缓解压力（更多的客户端）
- 随着系统资源的增加，如何持续改进（CPU，内存，硬盘，带宽）
- 并且满足可用性和性能目标
  - 低延迟
  - 满足高峰需求
  - 可调节的服务质量
- 分而治之通常是实现任何可伸缩性的目标最佳方法

分而治之

- 将处理分为多个小任务
  每个任务执行一个非阻塞操作
- 当任务被激活时就执行它
  这里，通常由一个 IO事件触发

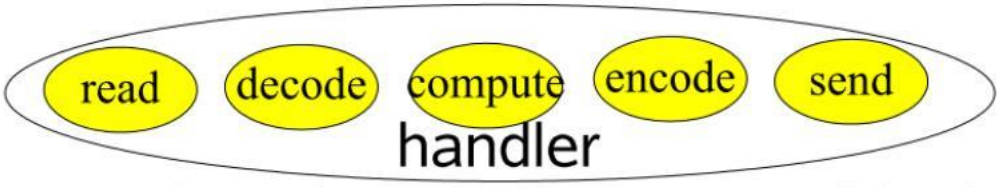

- java.nio支持这种机制
  - 非阻塞的读和写
  - 分配任务，为感兴趣的 IO 事件
- 无限可能的变化
  - 一系列事件驱动的设计

事件驱动设计

- 通常比其他模型更高效
  - 更少的资源：不需要一客户端一线程
  - 较少的开销：更少的上下文切换，更少的锁定
  - 但分派可能较慢：必须手动将操作绑定到事件
- 通常编程比较困难
  - 必须分解成简单的非阻塞操作
    - 类似于 GUI 事件驱动的操作
    - 不能消除所有阻塞：GC，page faults 等
  - 必须跟踪服务的逻辑状态

背景：AWT 中的事件

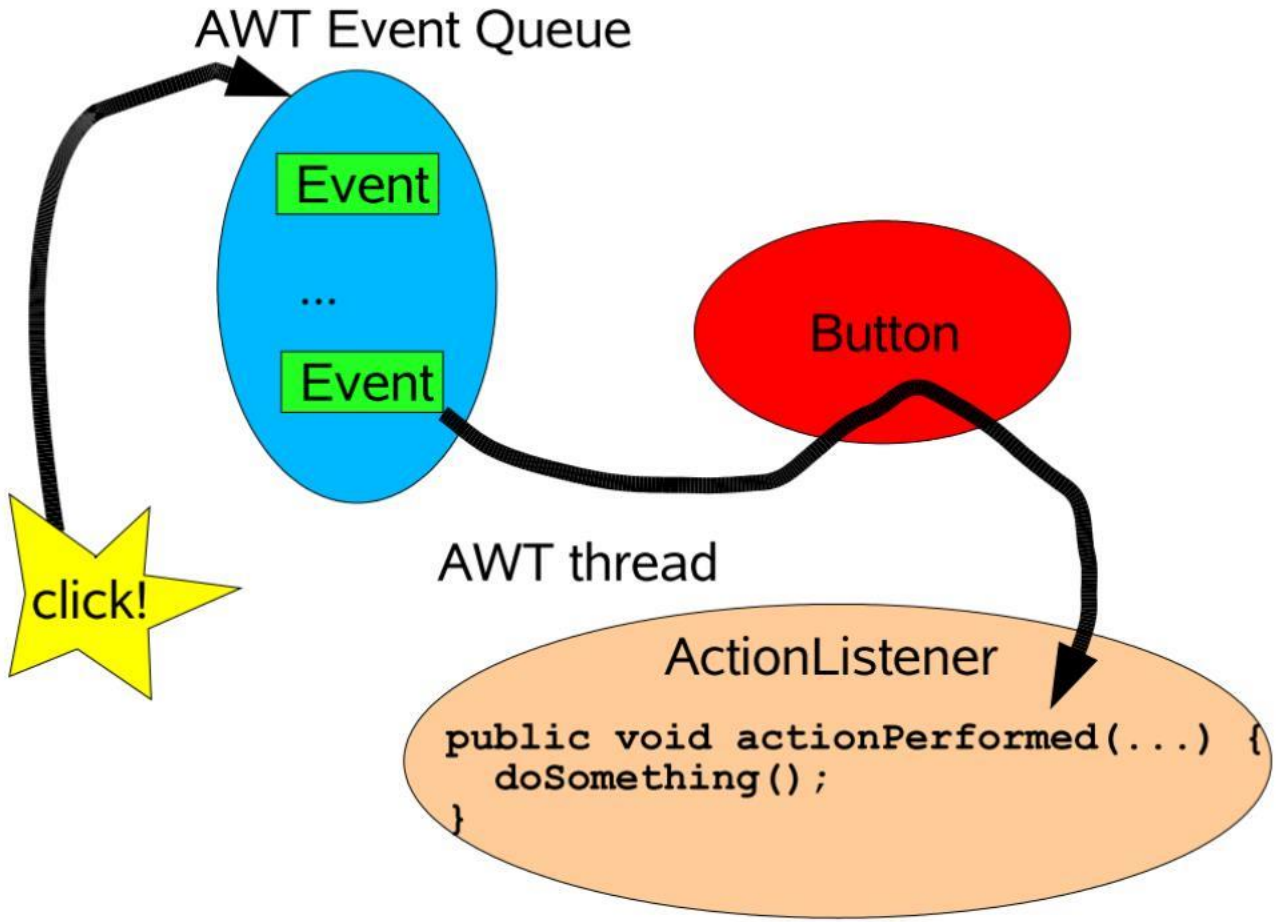

事件驱动 IO 使用类似的想法，但在设计上有所不同

Reactor 模式

- Reactor 通过分派合适的Handler来响应IO事件
  - 类似于 AWT 线程
- Handlers 执行非阻塞操作
  - 类似于 AWT 的 ActionListeners
- 通过绑定 Handlers 来管理事件
  - 类似于 AWT 的 addActionListener
- See Schmidt et al, *Pattern-Oriented Software Architecture, Volume 2* (POSA2)

  Also Richard Stevens's networking books, Matt Welsh's SEDA framework, etc

Reactor 基本设计

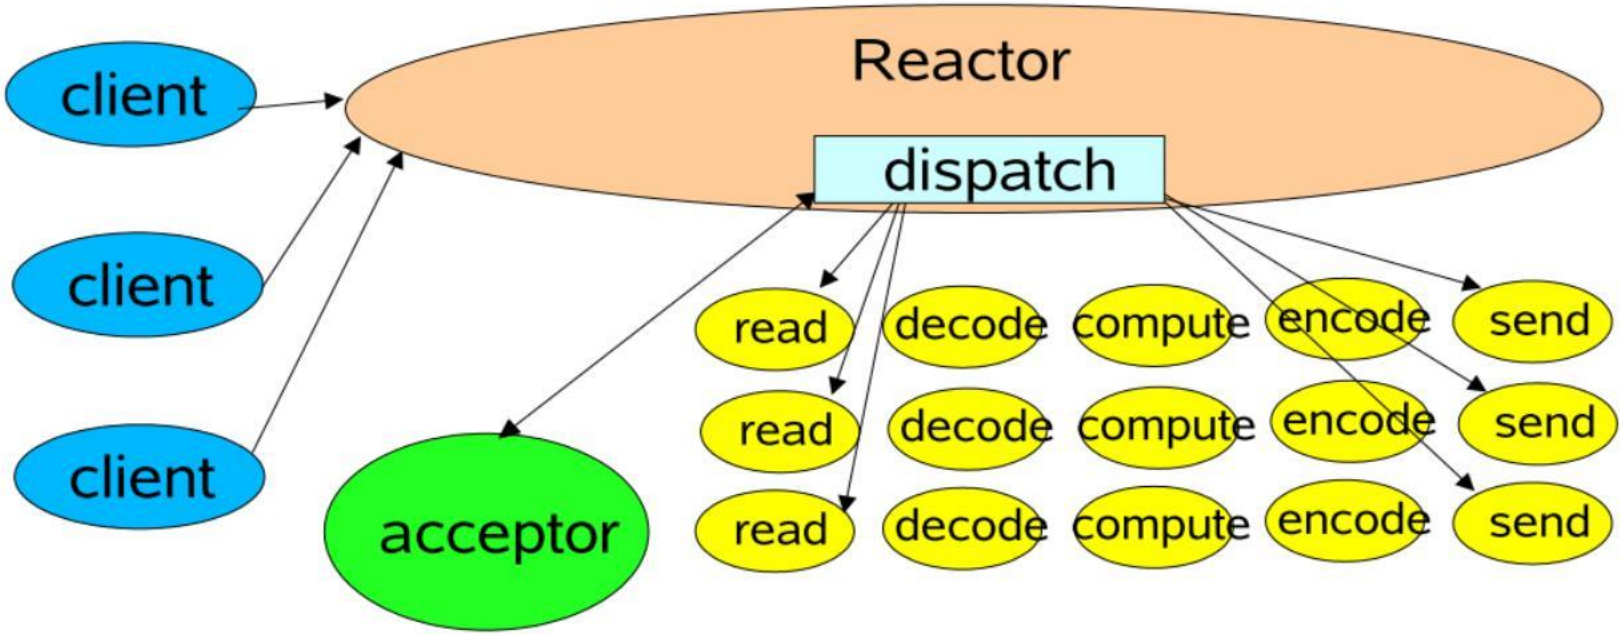

单线程版本

java.nio 提供的支持

- Channels
  - 连接到文件，Socket 等，支持非阻塞读取
- Buffers
  - 类似数组的对象，可由通道直接读取或写入
- Selectors
  - 通知哪组通道有 IO 事件
- SelectionKeys
  - 维护 IO 事件的状态和绑定信息

Reactor 1: Setup

```
class Reactor implements Runnable {
  final Selector selector;
  final ServerSocketChannel serverSocket;
  Reactor(int port) throws IOException {
    selector = Selector.open();
    serverSocket = ServerSocketChannel.open();
    serverSocket.socket().bind(
                    new InetSocketAddress(port));
    serverSocket.configureBlocking(false);
    SelectionKey sk =
      serverSocket.register(selector,
                      SelectionKey.OP_ACCEPT);
    sk.attach(new Acceptor());
  }
  /*
   Alternatively, use explicit SPI provider:
    SelectorProvider p = SelectorProvider.provider();
    selector = p.openSelector();
    serverSocket = p.openServerSocketChannel();
  */
```

Reactor 2: Dispatch Loop

```
// class Reactor continued
  public void run() {  // normally in a new Thread
    try {
      while (!Thread.interrupted()) {
        selector.select();
        Set selected = selector.selectedKeys();
        Iterator it = selected.iterator();
        while (it.hasNext())
          dispatch((SelectionKey)(it.next());
        selected.clear();
      }
    } catch (IOException ex) { /* ... */ }
  }
  void dispatch(SelectionKey k) {
    Runnable r = (Runnable)(k.attachment());
    if (r != null)
      r.run();
  }
```

Reactor 3: Acceptor

```
// class Reactor continued
  class Acceptor implements Runnable { // inner
    public void run() {
      try {
        SocketChannel c = serverSocket.accept();
        if (c != null)
          new Handler(selector, c);
      }
      catch(IOException ex) { /* ... */ }
    }
  }
}
```

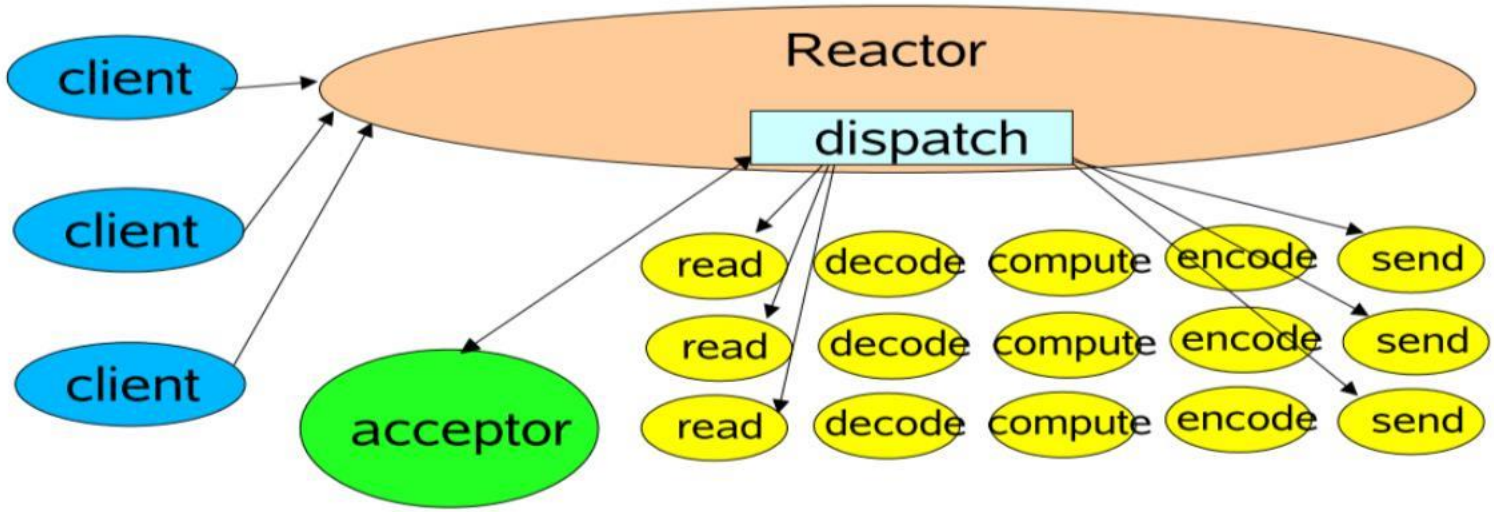

Reactor 4: Handler setup

```
final class Handler implements Runnable {
 final SocketChannel socket;
 final SelectionKey sk;
 ByteBuffer input = ByteBuffer.allocate(MAXIN);
 ByteBuffer output = ByteBuffer.allocate(MAXOUT);
 static final int READING = 0, SENDING = 1;
 int state = READING;
 Handler(Selector sel, SocketChannel c)
  throws IOException {
   socket = c; c.configureBlocking(false);
   // Optionally try first read now
   sk = socket.register(sel, 0);
   sk.attach(this);
   sk.interestOps(SelectionKey.OP_READ);
   sel.wakeup();
 }
 boolean inputIsComplete()  { /* ... */ }
 boolean outputIsComplete() { /* ... */ }
 void process()             { /* ... */ }
```

Reactor 5: Request handling

```
// class Handler continued
   public void run() {
    try {
      if      (state == READING) read();
      else if (state == SENDING) send();
    } catch (IOException ex) { /* ... */ }
  }
  void read() throws IOException {
    socket.read(input);
    if (inputIsComplete()) {
       process();
       state = SENDING;
       // Normally also do first write now
       sk.interestOps(SelectionKey.OP_WRITE);
    }
  }
  void send() throws IOException {
    socket.write(output);
    if (outputIsComplete()) sk.cancel();
  }
}
```

一个状态一个 Handler

GoF 状态对象模式的简单使用

重新绑定适当的 Handler 作为附件，附加对象

```
class Handler  { // ...
  public void run() { // initial state is reader
    socket.read(input);
    if (inputIsComplete()) {
      process();
      sk.attach(new Sender());
      sk.interest(SelectionKey.OP_WRITE);
      sk.selector().wakeup();
    }
  }
  class Sender implements Runnable {
    public void run(){ // ...
      socket.write(output);
      if (outputIsComplete()) sk.cancel();
    }
  }
}
```

多线程设计

- 为了可伸缩性适当的增加线程
  - 主要适用于多处理器
- Worker 线程
  - Reactor 应迅速触发 Handler
    - Handler 的处理过程会导致 Reactor 变慢
  - 将非 IO 操作的处理分离到其他线程
- 多个 Reactor 线程
  - Reactor 线程可以饱和 IO
  - 将负载分配到其他 Reactor
    - 负载平衡以匹配 CPU 和 IO 速率

Worker 线程

- 将非 IO 操作从 Reactor 线程中分离，提高其速度
  - 类似于 POSA2 Proactor 设计
- 比将计算限制处理改造成事件驱动简单
  - 应该还是纯粹的无阻塞计算
    - 充足的计算处理远比那点开销重要
- 但是处理与 IO 重叠的地方比较困难
  - 最好的方式是第一次读的时候读取全部的输入
- 使用线程池，线程数可调节控制
  - 通常需要的线程数比客户端数少的多

译者注：compute-bound 也叫做 CPU-bound，简单来说如果 CPU 快程序就快，就说明程序是受 CPU 限制的，此外还有 I/O-bound，memory-bound。

Worker 线程池

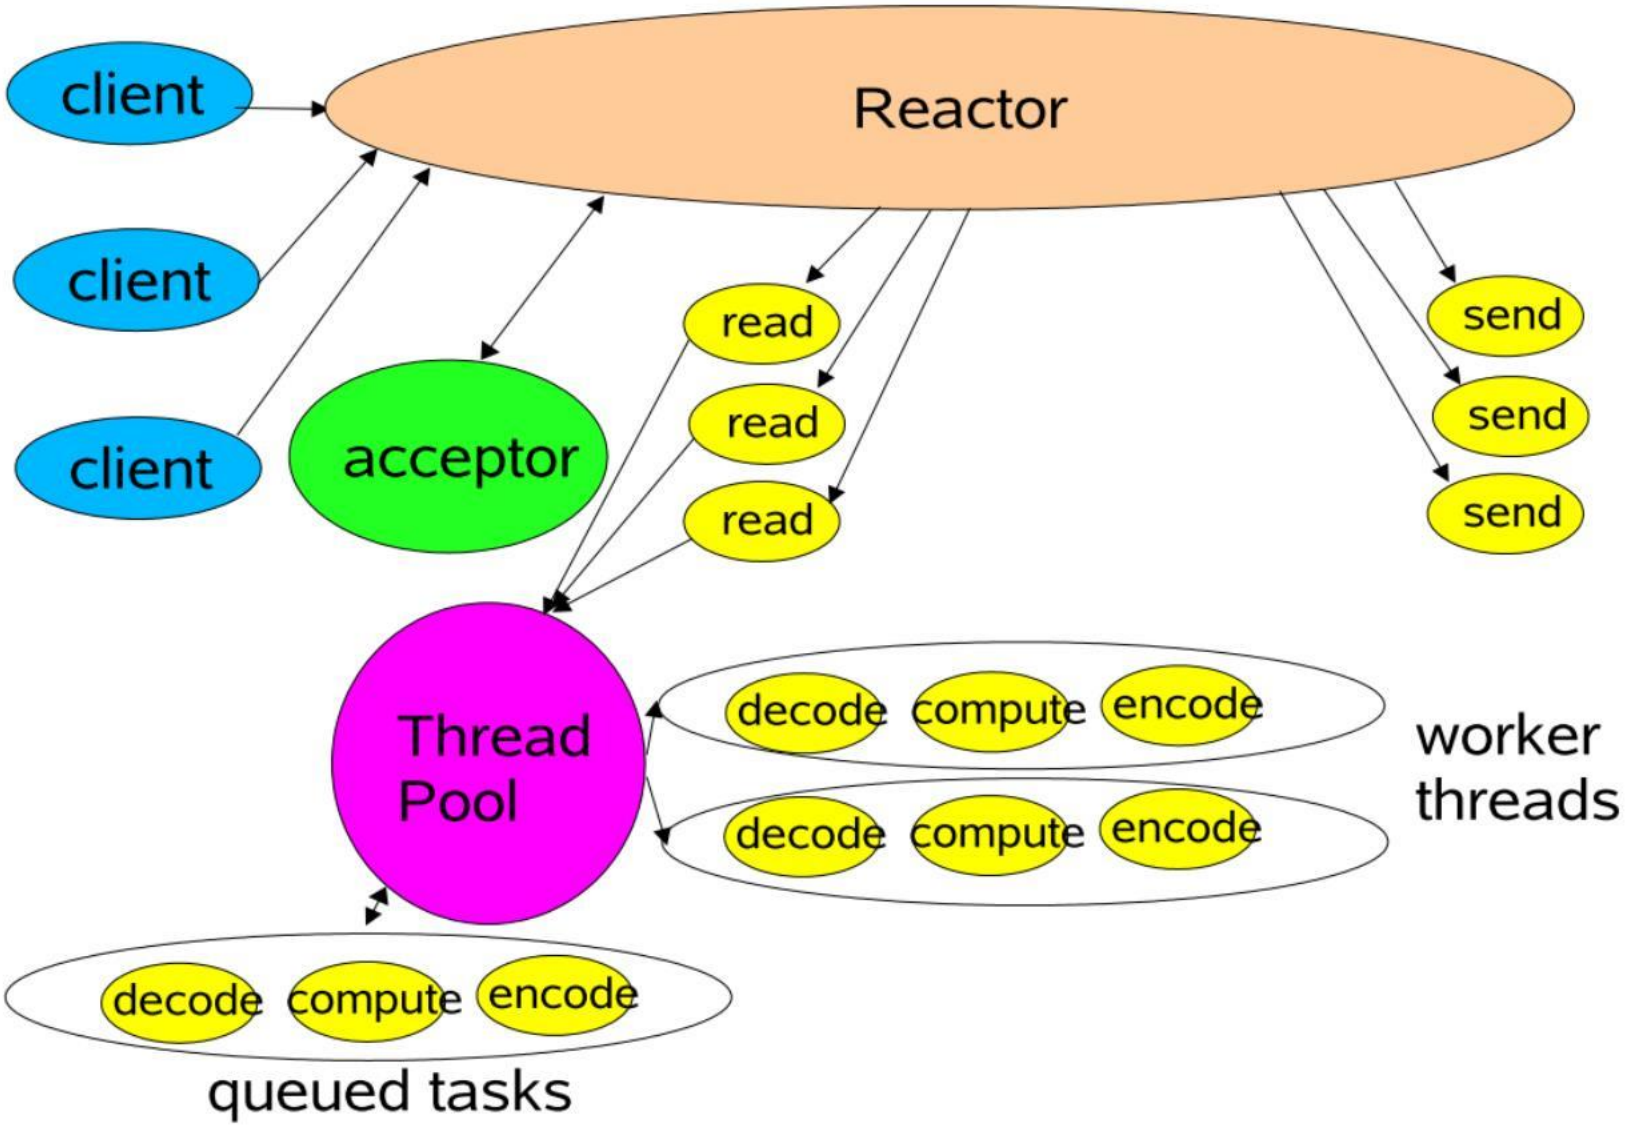
client
client
client
Reactor
acceptor
read
read
read
send
send
send
Thread Pool
decode
compute
encode
decode
compute
encode
worker threads
decode
compute
encode
queued tasks

Handler 使用线程池

```
class Handler implements Runnable {
  // uses util.concurrent thread pool
  static PooledExecutor pool = new PooledExecutor(...);
  static final int PROCESSING = 3;
  // ...
  synchronized void read() { // ...
    socket.read(input);
    if (inputIsComplete()) {
      state = PROCESSING;
      pool.execute(new Processer());
    }
  }
  synchronized void processAndHandOff() {
    process();
    state = SENDING; // or rebind attachment
    sk.interest(SelectionKey.OP_WRITE);
  }
  class Processer implements Runnable {
    public void run() { processAndHandOff(); }
  }
}
```

协调任务

- 切换（Handoffs）
  - 每个任务的启用，触发或调用下一个
  - 通常很快，但是很脆弱
- 回调每个 handler 的分派者
  - 设置状态，附加的对象等
  - GoF 中介模式的一种变种
- 队列（Queues）
  - 比如，跨阶段传递缓冲区
- Futures
  - 当每个任务产生结果时
  - 在顶层使用 join 或 wait/notify 进行协调

使用线程池

- 可调节的工作线程池
- 主要方法 `execute(Runnable r)`
- 线程池的控制：
  - 任务队列的种类（任何通道）
  - 最大和最小线程数
  - 缓和在线线程的需求
  - 保持存活间隔，直到空闲线程死亡
    - 如有必要，稍后将被新的替换
  - 饱和策略
    - 阻塞，删除，生产者运行，等

多个 Reactor 线程

- 使用 Reactor 池
  - 匹配 CPU 和 IO 的速率
  - 静态或动态结构
    - 有自己的 Selector、Thread、dispatch loop
  - 主 acceptor 向其他 reactor分配

```
Selector[] selectors; // also create threads
int next = 0;
class Acceptor { // ...
  public synchronized void run() { ...
    Socket connection = serverSocket.accept();
    if (connection != null)
      new Handler(selectors[next], connection);
    if (++next == selectors.length) next = 0;
  }
}
```

使用多个 Reactor

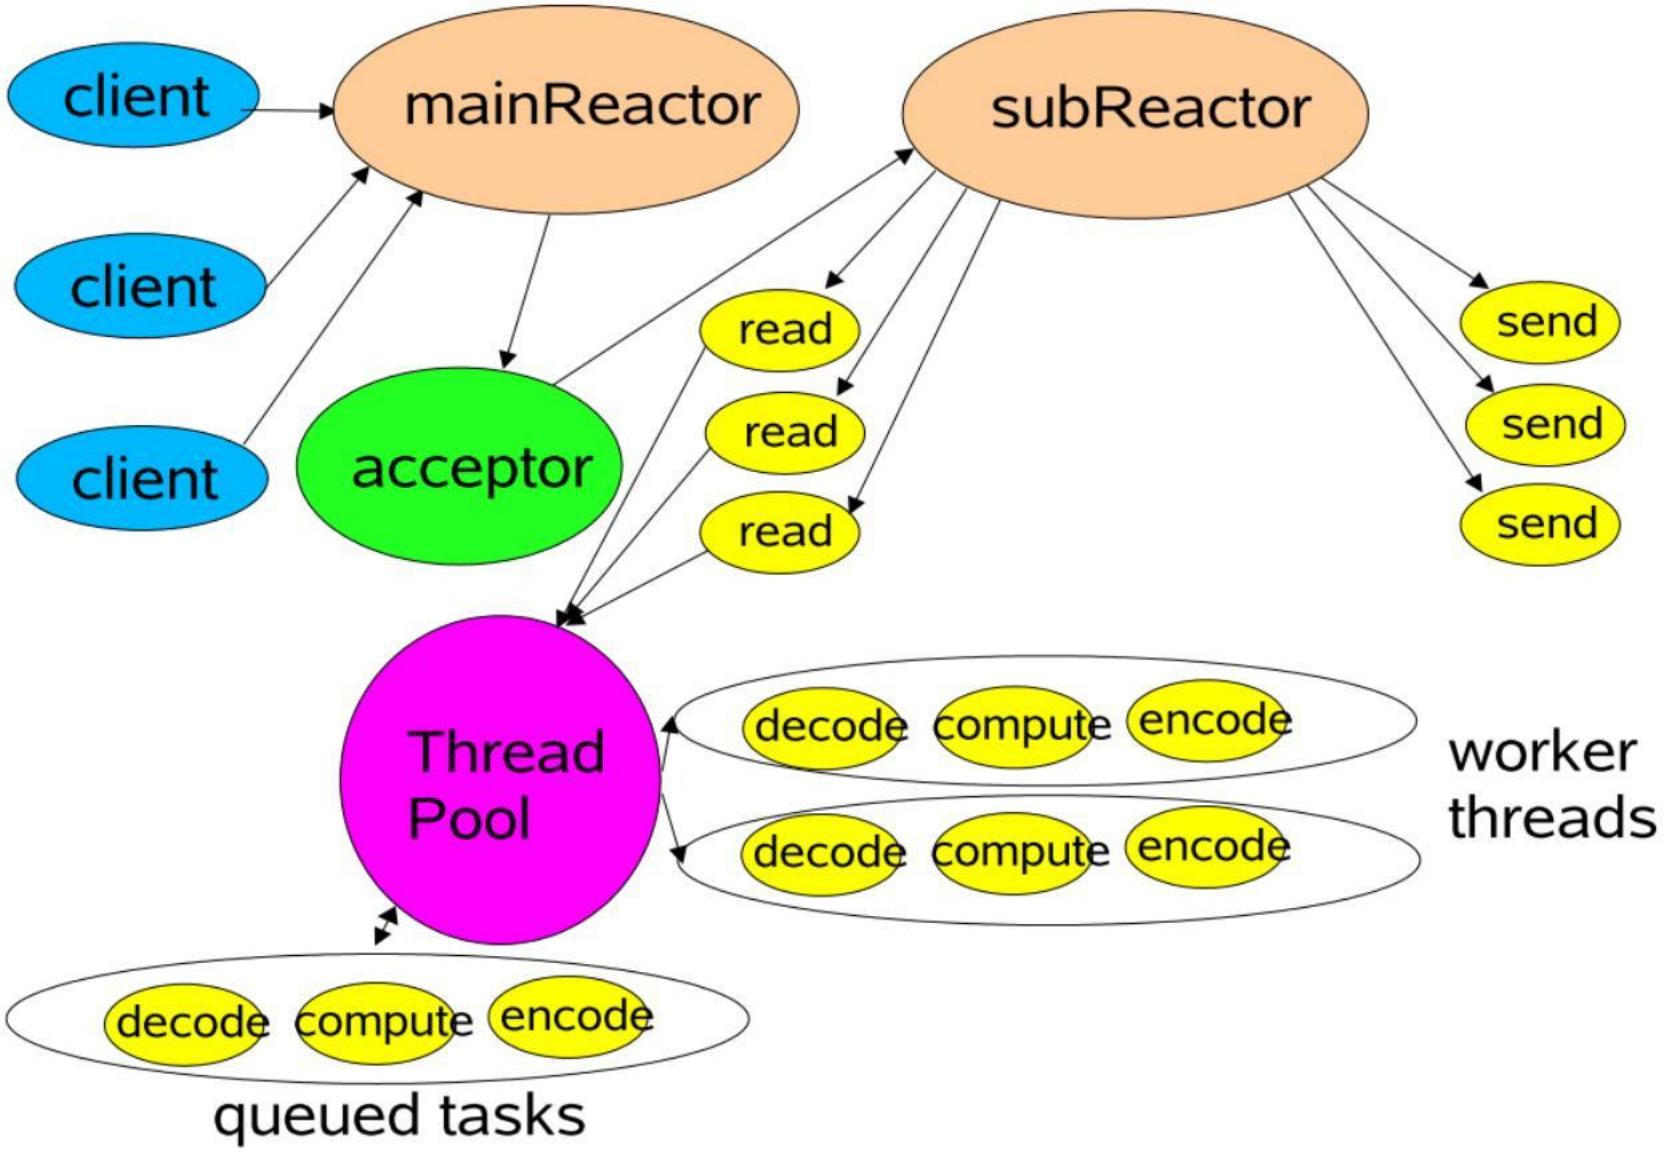

java.nio其他特性

- 一个 Reactor 多个 Selector
  - 将不同的 Handler 绑定不同的 IO 事件
  - 可能需要仔细同步才能协调
- 文件传输
  - file-to-net 或 net-to-file的自动拷贝
- 内存映射文件
  - 通过缓冲区访问文件
- 直接缓冲区
  - 有时可以实现零拷贝传输
  - 但是有初始化和回收开销
  - 适合长连接的应用

基于连接的扩展

- 替换单个请求服务，而是：
  - 客户端连接
  - 客户端发送一系列消息/请求
  - 客户端断开连接
- 示例
  - 数据库和事物监听器
  - 多人游戏、聊天等
- 可扩展基本服务模型
  - 处理多个长连接客户端
  - 跟踪客户端和会话状态（包括删除）
  - 跨主机的分布式服务

API 介绍

- Buffer
- ByteBuffer
  (CharBuffer, LongBuffer, etc not shown.)
- Channel
- SelectableChannel
- SocketChannel
- ServerSocketChannel
- FileChannel
- Selector
- SelectionKey

Buffer

```
abstract class Buffer {
  int     capacity(); // 总容量
  int     position(); // 当前可读或可写的位置
  Buffer  position(int newPosition);
  int     limit();  // 可读或可写的位置上限
  Buffer  limit(int newLimit);
  Buffer  mark();   // 设置标志位，mark = position
  Buffer  reset();  // 重置当前位置为标志位，position = mark
  Buffer  clear();  // position=0;mark=-1;limit=capacity;
  Buffer  flip();   // limit=position;position=0;mark=-1;
  Buffer  rewind(); // 重新读取，position=0;mark=-1;
  int     remaining();     // 返回limit和position之间的元素个数
  boolean hasRemaining(); // 判断limit和position之间是否有元素
  boolean isReadOnly();   // 只读
}
```

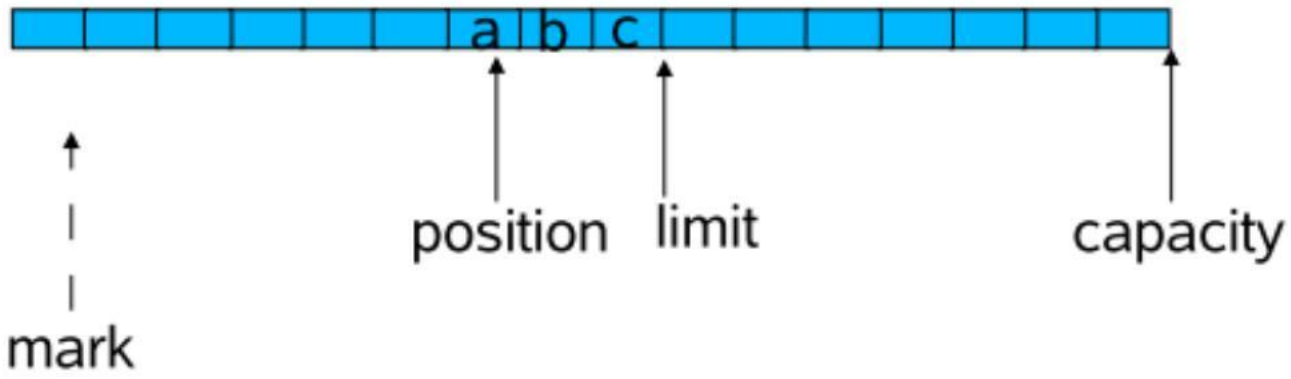

ByteBuffer

```
abstract class ByteBuffer extends Buffer {
  static ByteBuffer allocateDirect(int capacity);
  static ByteBuffer allocate(int capacity); // 创建对象
  static ByteBuffer wrap(byte[] src, int offset, int len);
  static ByteBuffer wrap(byte[] src); // 以上创建字节缓冲区对象
  boolean       isDirect(); // 是否使用直接内存
  ByteOrder     order(); // 字节序
  ByteBuffer    order(ByteOrder bo);
  ByteBuffer    slice(); // 剩余元素的视图，类似复制
  ByteBuffer    duplicate(); // 创建一个新的引用，不复制数据
  ByteBuffer    compact(); // 释放部分已读数据
  ByteBuffer    asReadOnlyBuffer();
  byte          get(); // 读取字节
  byte          get(int index);
  ByteBuffer    get(byte[] dst, int offset, int length);
  ByteBuffer    get(byte[] dst);
  ByteBuffer    put(byte b); // 写入字节
  ByteBuffer    put(int index, byte b);
  ByteBuffer    put(byte[] src, int offset, int length);
  ByteBuffer    put(ByteBuffer src);
  ByteBuffer    put(byte[] src);
  . . .
}
```

Channel

```
interface Channel {
  boolean isOpen();
  void    close() throws IOException;
}

interface ReadableByteChannel extends Channel {
  int     read(ByteBuffer dst) throws IOException;
}
interface WritableByteChannel  extends Channel {
  int     write(ByteBuffer src) throws IOException;
}

interface ScatteringByteChannel extends ReadableByteChannel {
  int     read(ByteBuffer[] dsts, int offset, int length)
            throws IOException;
  int     read(ByteBuffer[] dsts) throws IOException;
}
interface GatheringByteChannel extends WritableByteChannel {
  int     write(ByteBuffer[] srcs, int offset, int length)
            throws IOException;
  int     write(ByteBuffer[] srcs) throws IOException;
}
```

SelectableChannel

```
abstract class SelectableChannel implements Channel {
  int           validOps(); // 返回通道支持的操作
  boolean       isRegistered();
  SelectionKey  keyFor(Selector sel);
  SelectionKey  register(Selector sel, int ops)
                   throws ClosedChannelException; // 注册
  void          configureBlocking(boolean block)
                   throws IOException; // 设置阻塞或非阻塞
  boolean       isBlocking();
  Object        blockingLock(); // 锁对象，安全修改阻塞状态
}
```

SocketChannel

```
abstract class SocketChannel implements ByteChannel ... {
  static SocketChannel open() throws IOException;
  Socket  socket(); // 通道关联的 Socket 对象
  int     validOps();
  boolean isConnected();
  boolean isConnectionPending();
  boolean isInputOpen();
  boolean isOutputOpen();
  boolean connect(SocketAddress remote) throws IOException;
  boolean finishConnect() throws IOException;
  void    shutdownInput() throws IOException;
  void    shutdownOutput() throws IOException;
  int     read(ByteBuffer dst) throws IOException;
  int     read(ByteBuffer[] dsts, int offset, int length)
              throws IOException;
  int     read(ByteBuffer[] dsts) throws IOException;
  int     write(ByteBuffer src) throws IOException;
  int     write(ByteBuffer[] srcs, int offset, int length)
              throws IOException;
  int     write(ByteBuffer[] srcs) throws IOException;
}
```

ServerSocketChannel

```
abstract class ServerSocketChannel extends ... {
  static ServerSocketChannel open() throws IOException;
  int           validOps();
  ServerSocket  socket();
  SocketChannel accept() throws IOException;
}
```

FileChannel

```
abstract class FileChannel implements ... {
 int  read(ByteBuffer dst);
 int  read(ByteBuffer[] dsts);
 int  write(ByteBuffer src);
 int  write(ByteBuffer[] srcs);
 long position();
 void position(long newPosition);
 long size();
 void truncate(long size);
 void force(boolean flushMetaDataToo);
 int  transferTo(long position, int count,
                 WritableByteChannel dst); // 零拷贝
 int  transferFrom(ReadableByteChannel src,
                   long position, int count);
 FileLock lock(long position, long size, boolean shared);
 FileLock lock();
 FileLock tryLock(long pos, long size, boolean shared);
 FileLock tryLock();
 static final int MAP_RO, MAP_RW,  MAP_COW;
 MappedByteBuffer map(int mode, long position, int size);
}
NOTE: ALL methods throw IOException
```

Selector

```
abstract class Selector {
 static Selector open() throws IOException;
 Set  keys(); // 返回已注册的 key 集合
 Set  selectedKeys();
 int  selectNow() throws IOException;
 int  select(long timeout) throws IOException;
 int  select() throws IOException;
 void wakeup();
 void close() throws IOException;
}
```

SelectionKey

```
abstract class SelectionKey {
 static final int  OP_READ,     OP_WRITE,
                   OP_CONNECT, OP_ACCEPT;
 SelectableChannel channel();  // 注册的通道
 Selector          selector(); // 关联的 Selector
 boolean           isValid();  // key 是否有效
 void              cancel(); // key立即失效，下次select()清理
 int               interestOps(); // 感兴趣的事件
 void              interestOps(int ops);
 int               readyOps();
 boolean           isReadable();
 boolean           isWritable();
 boolean           isConnectable();
 boolean           isAcceptable();
 Object            attach(Object ob); // 附加一个对象
 Object            attachment(); // 获取附加的对象
}
```